

기말 프로젝트 보고서

CardioCare

종단간 머신러닝 시스템 구축

과목	기계학습
학과	컴퓨터공학과
학년	4
학번	202221016
이름	이성채

Github 주소 : https://github.com/sungchaelee/ML_Project

1. 문제 정의와 사용 목적

CardioCare는 환자의 임상 데이터(나이, 안정 시 혈압, 혈청 콜레스테롤, 최대 심박수, 운동 유발 협심증, ST 분절 변화 등)로부터 심장병의 존재 여부를 예측하는 이진 분류 시스템이다. 원 데이터의 타깃은 0~4의 다중 등급이지만, 본 프로젝트는 질환 유무 판단에 초점을 맞춰 0(정상)과 1(심장병)으로 이진화하였다.

이 시스템의 사용 목적은 분명하다: 심장 전문의의 의사결정을 보조하는 것이지, 진단을 대체하거나 단독으로 결정하는 것이 아니다 (inform, not decide). 모델은 환자의 심장병 위험에 대한 예측과 확률을 제시할 뿐이며, 최종 진단·치료 결정의 책임은 전적으로 의사에게 있다. 따라서 CardioCare는 자동 진단 장치가 아니라, 임상 현장에서 의사가 놓치기 쉬운 위험 신호에 주의를 환기시키는 '두 번째 의견' 도구로 설계되었다.

이 원칙은 시스템 전반의 설계에 직접 반영되었다. 첫째, 평가 지표를 단순 정확도가 아니라 recall과 balanced accuracy를 중심으로 삼았다. 심장병 환자를 정상으로 잘못 판정하는 False Negative는 치료 시기를 놓쳐 치명적 결과로 이어질 수 있어, 임상적으로 가장 비용이 큰 오류이기 때문이다. 둘째, 추론 단계에 로깅을 두어 모든 예측을 추적 가능하게 하고, 재학습 시 사람의 승인 게이트를 두어 human-in-the-loop를 보장하였다(6번 참조).

데이터는 UCI Heart Disease 통합본을 사용하였다. Cleveland·Hungary·Switzerland·VA 4개 기관의 처리된 데이터(processed*.data)를 결합해 총 920행을 확보하였으며, 단일 기관(Cleveland 303행)보다 표본이 크고 다양해 일반화에 유리하다고 판단하였다.

2. EDA 핵심 결과

통합 데이터셋은 총 920행, 14개 열(이진화 타깃 포함)로 구성된다. head()·info()·describe()로 확인한 결과, 연속형(age, trestbps, chol, thalach, oldpeak)과 범주형(sex, cp, fbs, restecg, exang, slope 등) 특성이 섞여 있었다.

① 타깃 분포

value_counts(normalize=True) 결과 심장병(1)이 약 55%, 정상(0)이 약 45%로 비교적 균형 잡혀 있었다[그림 1]. 그러나 균형이 양호하더라도 단순 정확도는 부적절하다고 판단했다. 임상 맥락에서 심장병 환자를 놓치는 False Negative가 가장 치명적이므로, 평가는 recall·balanced accuracy·F1·confusion matrix를 중심으로 보기로 결정했다.

결측값. 열별 결측률을 보면 ca(약 66%)·thal(약 53%)·slope(약 34%)가 심각했고, 나머지(fbs, oldpeak, trestbps, thalach, exang 등)는 0~10% 수준이었다. 특히 ca·thal은 절반 이상이 결측이라 신뢰할 만한 대치가 어렵다고 보았다.


② 숨은 결측

describe()에서 chol과 trestbps의 최솟값이 0임을 발견했다. 혈청 콜레스테롤과 안정 시 혈압이 0일 수는 없으므로, 이는 측정 누락이 0으로 코딩된 위장된 결측이다. chol == 0이 약 172행 (~22%)에 달했다. 단순 결측률만 보면 chol은 멀쩡해 보이지만 실제로는 약 1/5이 결측인 셈이다.


③ 이상치·이상값

연속형 특성을 boxplot과 IQR로 검토한 결과 통계적 이상치가 다수 존재했으나, 대부분 고령·고혈압 등 임상적으로 가능한 값이었다[그림 2]. 또한 oldpeak에서 생리학적으로 설명하기 어려운 음수값(예: -2.6)이 발견되어 측정/기록 오류 가능성을 확인했다.

요약하면, EDA는 ① 타킷은 균형 잡혔으나 임상적 비용 구조상 recall 중심 지표가 필요하고, ② 심각한 결측(ca·thal)과 숨은 결측(chol·trestbps의 0)을 구분해 다뤄야 하며, ③ 이상치는 임상적 타당성을 고려해 신중히 처리해야 함을 보여 주었다. 이 통찰은 섹션 3의 전처리 결정으로 직접 이어진다.



[그림 1] 타킷 분포 - "그림 1. 타킷 클래스 분포(0=정상 ~45%, 1=심장병 ~55%). 비교적 균형이나 임상적 비용 때문에 recall 중심 지표 채택."



[그림 2] 연속형 boxplot - "그림 2. 연속형 특성의 분포·이상치. chol·trestbps의 0값(측정 누락이 0으로 코딩된 숨은 결측)과 oldpeak 음수값이 드러난다."

3. EDA 결과에 근거한 전처리 결정

EDA에서 드러난 문제들을 아래와 같이 처리했으며, 모든 처리는 일회성 셀이 아니라 새 데이터에 그대로 재적용 가능한 함수와 sklearn의 ColumnTransformer 파이프라인으로 구현하였다.

(1) 숨은 결측 복원

chol과 trestbps의 0값은 실제 측정값이 아니라 누락이므로, 전처리 첫 단계에서 NaN으로 변환했다. 이 처리로 chol의 실제 결측률이 약 3%에서 약 22%로 드러나, 이후 대치 대상에 올바르게 포함되었다.

(2) 결측이 심한 열 삭제

ca(약 66%)와 thal(약 53%)은 절반 이상이 결측이었다. 이 정도면 어떤 대치도 추측으로 값을 채우는 것에 가까워 신뢰도가 낮고 편향을 주입할 위험이 크다고 판단해 두 열을 삭제했다. 반면 slope는 결측률이 약 34%로 높지만 절반에는 못 미치고 임상적으로 의미 있는 특성이라 유지하고 대치하기로 했다.

(3) 결측 대치 - 삭제 대신 대치

남은 결측은 행 삭제 대신 대치를 택했다. 920행은 의료 데이터로서 크지 않아 결측 행을 버리면 표본이 더 줄어들기 때문이다. 분포가 치우치고 이상치에 강건해야 하는 연속형(age, trestbps, chol, thalach, oldpeak)은 중앙값으로, 범주형(sex, cp, fbs, restecg, exang, slope)은 최빈값으로 대치했다.

(4) 이상치·이상값 처리

boxplot에서 보인 통계적 이상치는 대부분 고령·고혈압 등 임상적으로 가능한 실제 값이므로 제거하지 않고 유지했다. 무리한 제거는 오히려 드문 고위험 환자(가장 놓쳐선 안 되는 대상)를 버리는 결과가 될 수 있기 때문이다. oldpeak의 음수 값도 임상적으로 가능한 범위로 보아 유지했다.

(5) 중복·빈 열 정리

완전 중복 행을 제거해 920행에서 918행이 되었고, 값이 하나뿐이거나 비어 있는 열은 제거하도록 파이프라인에 포함했다.

(6) 데이터 누수 방지

데이터로부터 학습되는 모든 변환(중앙값·최빈값 임putation, 스케일러, 특성 선택기)은 학습 fold에만 fit하고 검증/테스트에는 transform만 적용했다. 이를 위해 대치를 단일 셀이 아니라 ColumnTransformer로 구성하여, 학습/평가 분할 이후 학습 데이터에만 적합되도록 하였다.

4. MLflow 실험 기반 모델 비교 및 최종 선택

4.1 실험 설계

데이터는 train_test_split으로 학습 80% / 테스트 20%(734행 / 184행)로 나누었고, 타깃 비율을 유지하기 위해 층화 분할, 재현성을 위해 고정 시드(random_state=42)를 사용했다. 스케일링은 모델 특성에 맞춰 적용했다. 거리·마진 기반인 Logistic Regression과 SVC에는 StandardScaler를 학습

데이터에만 fit하여 누수를 방지했고, 트리 기반인 Random Forest에는 스케일링을 적용하지 않았다. 특성 선택은 분할 이후 Random Forest 기반 SelectFromModel(threshold="median")로 수행했으며, 선택된 특성은 age, trestbps, chol, thalach, oldpeak, cp였다. 세 모델은 5-fold 층화 교차검증으로 비교했고, 모든 실행의 파라미터·지표·학습된 모델 아티팩트·모델 계열 태그를 MLflow에 기록했다.

4.2 모델 비교

모델	CV bal-acc	Test bal-acc	Recall	F1	FN
Logistic Regression	0.763	0.789	0.833	0.817	17
SVC	0.766	0.777	0.882	0.822	12
Random Forest	0.765	0.762	0.804	0.792	20

표 1. 모델 비교(5-fold 교차검증 + 테스트셋). precision 등 전체 지표와 confusion matrix는 MLflow에 기록되어 있으며, 표에는 임상적으로 핵심인 지표를 발췌했다.

세 모델 중 **SVC가 recall(0.882)과 False Negative(12건) 모두에서 가장 우수했다**. 이에 SVC를 최종 후보로 선정하고, GridSearchCV(scoring="recall", 5-fold)로 하이퍼파라미터를 탐색했다. 최적 조합은 C=0.1, gamma=0.01, kernel="rbf"였고, 교차검증 recall은 **0.889**였다. 튜닝된 SVC의 최종 테스트 성능은 다음과 같다.

balanced accuracy 0.773 · precision 0.772 · recall 0.863 · F1 0.815 · **FN 14**
 Confusion matrix [[TN 56, FP 26], [FN 14, TP 88]]

4.3 최종 선택 정당화

최종 모델로 튜닝된 **SVC**를 선택했다. SVC는 세 계열 중 recall이 가장 높고 FN이 가장 적어, 심장병 환자를 정상으로 놓치는 임상적으로 가장 비용이 큰 오류를 최소화하기 때문이다. 하이퍼파라미터 튜닝은 단일 테스트 분할이 아니라 교차검증 recall(0.889)을 기준으로 수행하여 일반화 성능을 우선했고, 그 결과 더 강하게 정규화된 파라미터(C=0.1)를 얻어 과적합 위험을 낮췄다. 최종 confusion matrix에서 FP(26건)보다 FN(14건)을 줄이는 방향은, 의심 환자를 일단 의사에게 알려 검토받게 하는 "inform, not decide" 원칙에 부합한다. precision(0.772)이 다소 낮아 일부 정상 환자가 양성으로 분류되지만, 이는 의사의 추가 검토로 걸러질 수 있는 비용이며 환자를 놓치는 것보다 훨씬 낫다고 판단했다.

5. 테스트와 패키징

5.1 단위테스트 - 무엇을, 왜?

tests/test_pipeline.py에 의미 있는 단위 테스트 4개를 작성했다. 단순히 통과를 위한 자명한 명제

가 아니라, 추론 파이프라인에서 실제로 발생할 수 있는 버그를 잡도록 설계했다.

1. **예측 shape 일치** - 입력 N행에 대해 예측이 정확히 N개 나오는지 검증한다. 행 정렬이 어긋나면 환자와 예측이 잘못 매핑되어 임상에서 치명적이기 때문이다.
2. **확률 범위·합** - predict_proba의 출력이 각 원소 [0, 1] 범위이고 행마다 합이 약 1인지 확인한다. 이 조건이 깨지면 출력을 위험 '확률'로 해석할 수 없다.
3. **입력 범위 검증** - chol이 [0, 600] 등 임상적으로 정해진 범위를 벗어난 입력(예: 음수, 비현실적 값)을 잡아낸다. 잘못된 입력에 대한 무의미한 예측을 막는다.
4. **결정론(determinism)** - 고정 시드에서 동일 입력이 항상 동일 출력을 내는지 확인한다. 재현성과 감사가능성(같은 환자에게 같은 결과)을 보장한다.

5.2 Docker 패키징

추론 환경을 재현 가능하게 컨테이너화했다.

python:3.12-slim 베이스 위에 버전이 고정된 경량 의존성(requirements-inference.txt)만 설치하고, 코드·저장된 모델·샘플 입력을 복사한 뒤 추론 스크립트를 엔트리포인트로 둔다. docker build -t cardiocare:1.0 .로 빌드되며, docker run으로 data/sample_input.csv에 대한 예측을 정상 출력하는 것을 확인했다. 이미지에는 비밀값을 포함하지 않았고, 슬림 베이스와 추론 전용 의존성으로 이미지를 가볍게 유지했다.

5.3 CI

GitHub Actions로 모든 push마다 단위 테스트가 자동 실행되도록 구성했고, main 브랜치는 green 상태를 유지한다. 코드 변경이 위 핵심 불변식(shape·확률·범위·결정론)을 깨뜨리지 않음을 지속적으로 보장한다.

5.4 피쳐 스토어 / 모델 레지스트리 (실제 배포x, 논리 제시)

- 피쳐 스토어에 넣을 피쳐: chol. chol은 "0을 결측으로 간주 → 중앙값 대체"라는 비자명한 정의를 거친다. 이 정의를 피쳐 스토어에서 중앙 관리하면 학습과 서빙이 동일한 변환을 공유하게 되어 training-serving skew를 방지할 수 있다.
- 모델 레지스트리에 기록할 메타데이터: 검증 recall(및 FN). recall은 임상 안전상 가장 중요한 지표다. 이를 모델 버전별로 레지스트리에 기록하면, 안전 기준(예: recall 하한)에 미달하는 모델의 배포를 막는 승인 게이트로 활용할 수 있다(섹션 6의 human-in-the-loop 승인 근거).

6. 드리프트 결과 및 재학습/피드백 계획

6.1 모니터링 계측

추론 경로에 logging 기반 계측을 추가하여, 매 예측마다 타임스탬프·모델 버전·입력 shape·예측값 (가능한 경우 실제 정답 기반 balanced accuracy)을 logs/inference.log 파일에 기록한다. 이를 통해 어떤 버전의 모델이 언제 무엇을 예측했는지 사후 추적할 수 있다.

6.2 드리프트 감지(KS 검정)


테스트셋 복사본에 인위적 드리프트를 주입했다 - chol 평균 +50·분산 $\times 1.5$, thalach -25, oldpeak +1.5. 각 연속형 특성에 대해 학습 분포와 후보 분포를 scipy.stats.ks_2samp로 비교하고, $p < 0.05$ 인 특성을 드리프트로 플래그했다.

특성	학습 vs 원본(p)	학습 vs 드리프트(p)	드리프트
age	0.879	0.879	No
trestbps	1.000	1.000	No
chol	0.711	0.000	Yes
thalach	0.706	0.000	Yes
oldpeak	0.978	0.000	Yes

표 2. KS 검정 결과. 기준선(학습 vs 원본)은 모든 특성이 $p > 0.05$ 로 오탐이 없고, 드리프트 주입 후에는 실제로 이동시킨 chol·thalach·oldpeak만 정확히 플래그된다(건드리지 않은 age·trestbps는 변화 없음)

6.3 입력 드리프트 ↔ 성능 저하

같은 모델로 평가한 balanced accuracy가 원본 테스트셋 **0.773**에서 드리프트셋 **0.594**로 약 **0.18** 하락했다. 입력 분포 변화가 곧바로 성능 저하로 이어짐을 확인했다. 드리프트 강도를 시간에 따라 키운 시계열에서도 정확도가 경고 임계값(0.70) 아래로 떨어지는 것을 시각화했다[그림 3].



[그림 3] 드리프트 강도가 커질수록(합성 타임스탬프) balanced accuracy가 경고 임계값(0.70) 아래로 하락. 입력 드리프트와 성능 저하의 연관을 보여준다.

6.4 재학습 정책

두 정책을 병행한다.

드리프트 트리거: 주요 특성에 KS 드리프트($p < 0.05$)가 감지되고 모니터링 balanced accuracy가 임계값(예: 0.70) 아래로 떨어지면 재학습을 트리거한다.

정기 재학습: 이와 별개로 분기마다 재학습해, 임계값을 넘지 않는 완만한 드리프트도 주기적으로 흡수한다. 정기 학습이 안전망, 트리거가 급변 대응 역할을 한다.

6.5 Human-in-the-loop 개입 지점

1. **예측** - 모델은 위험도를 참고용으로 제시할 뿐, 최종 진단은 의사가 내린다(inform, not decide).
2. **재학습** - 트리거가 자동 발동해도 새 모델을 자동 배포하지 않는다. 검토자가 새 모델의 recall·FN을 확인하고 임상 안전 기준 충족 시에만 승인·배포한다.
3. **라벨 수집** - 정답(라벨)은 모델 예측이 아니라 독립적인 확정 진단(검사 결과 등)에서 수집한다.

6.6 폭주(runaway) 피드백 루프 위험

모델 예측이 의사 판단에 영향을 주고, 그 판단이 다시 라벨이 되어 모델이 '자기 예측'을 정답처럼 재학습하면 편향이 스스로 강화되며 폭주할 수 있다(예: 특정 그룹을 과소진단 → 검사 덜 시행 → 양성 라벨 감소 → 더 심한 과소진단). 완화책은 ① 라벨을 예측과 독립적인 확정 진단으로 수집, ② 재학습 전 사람 승인 게이트, ③ 그룹별 성능 정기 감사, ④ 예측을 자동 결정이 아닌 보조 정보로만 제시하는 것이다.

7. 서빙 선택: Model-as-a-Service

CardioCare는 Model-as-a-Service로 서빙하되, 공용 클라우드가 아니라 **병원 내부망의 온프레미스 서버**에 모델을 호스팅하는 방식을 선택한다. 지연 시간·개인정보·업데이트 주기 세 관점에서 정당화한다.

업데이트 주기: 가장 결정적인 이유다. 본 프로젝트는 드리프트 모니터링과 하이브리드 재학습(섹션 6)을 설계했는데, MaaS는 모델을 한 곳에 호스팅하므로 재학습된 모델을 한 번 배포하면 모든 클라이언트가 즉시 최신 버전을 사용한다. 반면 on-device는 각 단말에 업데이트를 일일이 배포·동기화해야 해 드리프트 트리거 재학습을 신속히 반영하기 어렵고 버전 불일치가 생긴다. 중앙집중식 모니터링·재학습 인프라와 MaaS가 자연스럽게 맞물리게 된다.

개인정보(PHI): MaaS의 일반적 약점은 환자 데이터를 서버로 전송한다는 점이다. 이를 온프레미스 호스팅으로 해소한다. 모델 서버를 병원 내부망에 두면 PHI가 외부로 나가지 않고, 전송 구간 암호화·접근 통제, 그리고 섹션 6의 추론 로깅을 통한 감사 추적을 결합하면 프라이버시 위험을

관리할 수 있다. 즉, on-device의 프라이버시 이점을 상당 부분 확보하면서 중앙 관리의 장점을 유지한다.

지연 시간: CardioCare는 실시간 임베디드 응답이 필요한 시스템이 아니라, 의사가 환자를 검토하는 맥락에서 위험도를 제시하는 보조 도구다. 내부망 API 호출의 초 단위 지연은 임상 워크플로에 충분히 허용된다. 따라서 on-device가 주는 초저지연 이점은 이 용례에서 실질적 가치가 작다.

결론: 업데이트 신속성이 임상 안전(드리프트 대응)에 직결되고, 온프레미스 호스팅으로 PHI 우려를 해소할 수 있으며, 지연은 비임계적이다. 따라서 온프레미스 MaaS가 CardioCare에 가장 적합한 서빙 방식이다.

8. 한계, 윤리적 고려 사항, 향후 계획

8.1 한계

- **데이터 규모·이질성:** 920행은 의료 ML로서 작은 표본이며, 4개 기관 통합본은 측정 프로토콜과 환자군 차이로 이질적이다. chol의 숨은 결측(약 22%)은 중앙값으로 메웠으나 불확실성을 남기고, 결측이 심한 ca-thal은 삭제하여 잠재적으로 유용한 정보를 잃었다.
- **모델 성능:** 최종 balanced accuracy 0.773, precision 0.772로 상당한 false positive가 존재한다. 단독 임상 사용 수준은 아니며, 어디까지나 보조 도구로 한정된다.
- **외부 검증 부재:** 교차검증과 고정 분할로 평가했지만 진정한 독립 데이터셋에서의 외부 검증은 수행하지 못했다. 따라서 새로운 환자군에 대한 일반화는 검증되지 않았으며, 우리가 섹션 6에서 시뮬레이션한 드리프트가 실제로 발생할 수 있는 위험이다.
- **타깃 이진화:** 0~4 등급을 0/1로 단순화하면서 질환 중증도 정보를 잃었다.

8.2 윤리적 고려

- **inform, not decide 재확인 - 자동화 편향 위험:** 의사가 모델을 과신하면 보조도구가 사실상 결정자가 될 수 있다. 시스템을 두 번째 의견으로 명확히 제한하고 human-in-the-loop를 유지하여 이를 완화한다.
- **공정성:** 특정 기관·인구집단 위주의 데이터는 집단별 성능 불균형을 낳을 수 있다. 성별·연령·출처 기관별 성능 감사가 필요하며, 이는 §6의 폭주 피드백 루프 완화책과 직접 연결된다.
- **명시적 트레이드오프:** recall을 우선한 선택은 윤리적 트레이드오프다. False Negative를 줄이는 대신 False Positive(불필요한 불안과 추가 검사)를 감수한다. 이 선택을 임상자에게 투명하게 고지해야 한다.

8.3 1주가 더 주어진다면?

- **외부 검증:** 독립 데이터셋으로 실제 일반화 성능을 측정한다.
- **결측 처리 고도화:** chol에 KNN-모델 기반 대치를 시도하고, ca-thal을 결측 지시자와 함께 재활용하는 방안을 검토한다.
- **확률 보정:** Platt/isotonic 보정으로 예측 확률의 신뢰성을 확보하여 임상 임계값 설정에 활용한다.
- **결정 임계값 튜닝:** 기본 0.5 대신 목표 recall(예: ≥ 0.90)을 달성하도록 임상의와 협의해 임계값을 조정한다.
- **설명가능성:** SHAP 등으로 예측 근거를 제시해 알린다는 목표를 강화하고, 집단별 공정성 감사를 병행한다.

[부록] AI 도구 사용

본 프로젝트는 AI 도구로 Anthropic의 Claude를 사용하였다. Claude는 주로

- ① 코드 보일러플레이트·일부스캐폴딩 작성 (전처리·학습·추론·모니터링 모듈, Dockerfile 설정 초안)
- ② 디버깅 (MLflow 파일 스토어 및 모델 직렬화 오류, Docker의 scikit-learn 버전 불일치, 터미널 출력 해석 등)
- ③ 개념 설명(어려운 용어 설명, 임상 맥락에 따른 평가 지표 선택 근거 등의 학습)
- ④ 본 보고서 초안 문장 정리에 활용되었다. (과제 조준에 맞는 용어 변경 등)

다만 모든 코드는 본인이 직접 로컬 환경에서 실행·검증하였고, 데이터 처리·모델 선택·서빙 및 재 학습 전략 등 핵심 판단은 본인이 결정하여 진행했다.